EXAME DE QUALIFICAÇÃO · PPGCC

Índice temporal informacional a partir de notícias corporativas

Uma proposta para empresas brasileiras de saneamento

Estudo de caso: Sabesp / SBSP3

Gabriel Felipe Souza Santos
Orientador: Prof. Dr. Michel Carlo Rodrigues Leles

2026

Uma notícia pode ter perspectivas diferentes

CONSUMIDOR **SABESP**

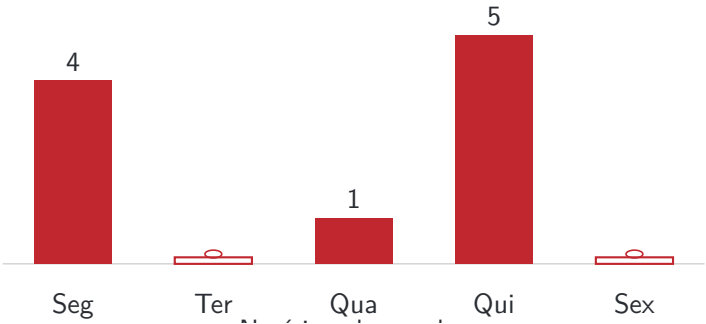
Exemplo hipotético: reajuste da tarifa de água

Possível aumento da despesa

Possibilidade de aumento de receita

A classificação precisa declarar o alvo: Sabesp.

A publicação de notícias é irregular



DADOS ILUSTRATIVOS

Zero observado não comprova ausência de publicação.

Precisamos definir uma regra para cada dia elegível.

Dissertação, §4.2

O problema combina alvo, classificação e tempo

1 · ALVO

Que informação se refere à Sabesp?

→

2 · CLASSIFICAÇÃO

O modelo responde à tarefa definida?

→

3 · TEMPO

Que histórico entra na comparação?

Lacuna no estudo de caso: validar a entrada contextual e comparar agregações sob informação equivalente.

Dissertação, §1.1 e §3.5

A hipótese compara associações, sem presumir superioridade

Como a representação textual e a agregação temporal afetam o indicador e sua associação com retornos posteriores da SBSP3?

$$\Delta\rho = \rho_S(ITI^{(7)}, R^{(1)}) - \rho_S(Soft, R^{(1)})$$

Spearman: associação entre ordenações · $R^{(1)}$: retorno da semana seguinte

$\Delta\rho \neq 0$

Objetivo: desenvolver e avaliar um procedimento reprodutível no caso Sabesp.

Dissertação, §§1.1–1.3 e Eq. iti-delta (§4.5)

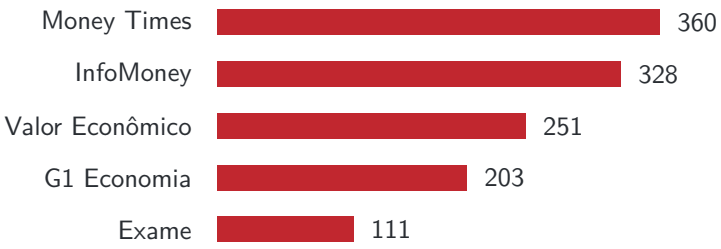
A literatura sustenta três decisões do procedimento

Antecedente	Decisão apoiada	Limite
FinBERT-PT-BR		
Santos et al. (2023)	Classificador financeiro	
em português	Adequação à Sabesp	
ainda precisa de avaliação		
SemEval · SEntFiN · FinEntity	Definir o alvo	
do sentimento	Recorte não equivale	
a orientação		
Shapiro et al. (2022) ·	Agregar notícias	

Contribuição: integração documentada e avaliação crítica no caso Sabesp.

A campanha temporal reúne 1.253 notícias canônicas

1.254 registros brutos - 1 duplicata = 1.253 notícias canônicas



5 veículos
Maio/2022
a abril/2024
(aproximadamente)

O corpus inventariado não equivale à totalidade das publicações.

Dissertação, §4.2; Apêndice B, tabela corpus-p02

Duas avaliações respondem a perguntas diferentes

Notícias relacionadas à Sabesp

DIAGNÓSTICO TEXTUAL

100 notícias documentais
Classes previstas $\times$ rótulos do autor
Saída: concordância por notícia

AVALIAÇÃO TEMPORAL

Recorte Sabesp $\rightarrow$ probabilidades
Escores $\rightarrow$ indicadores $\rightarrow$ retornos
Saída: associação por semana

Rótulos humanos não treinaram nem corrigiram automaticamente o ITI.

Dissertação, §4.1, figura pipeline; §§5.1–5.2

O recorte aproxima a entrada da menção à Sabesp

ESQUEMA ILUSTRATIVO · posições de sentenças, não uma notícia real

Posição	Tratamento
Anterior distante	Não selecionada neste esquema
Vizinha anterior	Selecionada, quando disponível
Menção explícita à Sabesp	Selecionada
Vizinha posterior	Selecionada, quando disponível
Posterior distante	Não selecionada neste esquema

→ **Entrada contextual Reunir os trechos selecionados nas menções encontradas.**

~~**Preparação da entrada não equivale a treinamento por entidade.**~~

Dissertação, §4.4

O FinBERT atribui probabilidades a três classes

FinBERT-PT-BR · classificador financeiro em português



$p_i^+ + p_i^- + p_i^0 = 1$

Entrada: até 512 tokens

Exemplo ilustrativo · probabilidades de classes, não de valorização.

Dissertação, §§2.2–2.3 e §4.4; Santos et al. (2023)

O escore resume o balanço entre positivo e negativo

$$s_i = p_i^+ - p_i^-$$

$$0{,}60 - 0{,}10 = +0{,}50$$

i: notícia
s_i: escore da notícia
p_i^+ e p_i^-: probabilidades positiva e negativa



Exemplo ilustrativo · escore zero não identifica sozinho a classe neutra.

Dissertação, §4.5, Eq. iti-escore; §2.3 e Apêndice C

A entrada diária é a média dos escores observados

$$X_d = \frac{1}{n_d} \sum_{i \in \mathcal{N}_d} s_i, \qquad n_d > 0$$

d: dia civil · X_d: entrada diária
$\mathcal{N}_d$: notícias elegíveis observadas no dia
n_d: quantidade dessas notícias
s_i: escore de cada notícia

$$\frac{0{,}50 - 0{,}20 + 0{,}10}{3} \approx 0{,}1333$$

Dia elegível sem notícia: $X_d = 0$
Fora da cobertura: não criar sinal

Exemplo ilustrativo · pesos iguais; zero não comprova neutralidade.

Dissertação, §4.5, Eq. iti-entrada-diaria; Apêndice C

Soft observa o dia; ITI conserva parte do histórico

SOFT · SEM MEMÓRIA

Entrada diária no corte
Sem notícia nesse dia: zero

ITI · COM MEMÓRIA

Estado anterior + entrada diária
Sem entrada: o estado decai

O estado segue para o dia seguinte

Memória do indicador não é memória comprovada dos investidores.

Dissertação, §4.5

Sete dias definem a meia-vida, não um ótimo

$$\lambda_H = 2^{-1/H} \qquad H = 7 \Rightarrow \lambda_7 \approx 0{,}9057$$

$$ITI_d = \lambda_H ITI_{d-1} + (1 - \lambda_H) X_d$$

H: meia-vida em dias civis
λ_H: fração diária retida
ITI_(d-1): estado anterior · X_d: entrada atual

90,57% do estado anterior
9,43% da entrada atual

Sem novas entradas: metade do estado remanescente após 7 dias.

Dissertação, §4.5, Eqs. iti-lambda e iti-recorrencia; Apêndice C

Uma atualização leva o ITI de 0,20 a 0,2283

SIMULAÇÃO DIDÁTICA · estado anterior 0,20 · entrada atual 0,50

$$0{,}9057 \times 0{,}20 \approx 0{,}1811$$

Contribuição do estado anterior

$$0{,}0943 \times 0{,}50 \approx 0{,}0472$$

Contribuição da entrada atual

$$ITI_d \approx 0{,}1811 + 0{,}0472 = 0{,}2283$$

Dissertação, §4.5

As referências usam históricos e pesos diferentes

Indicador	Informação considerada	Ponderação
Soft pontual	Entrada do dia de corte	Sem histórico
Média semanal	Sábado até o corte	
Dias elegíveis, inclusive zeros	Mesmo peso por dia	
ITI-H7	Até o corte, incluindo	
semanas anteriores	Memória exponencial	

Mesmas probabilidades de origem; janelas de informação não idênticas.

Dissertação, §4.5, tabela baselines-temporais

O corte textual antecede o último pregão

Corte: fim do dia civil anterior ao último pregão da semana

QUINTA · noite
Sinal textual no corte

⟶

SEXTA · semana w
Fechamento ajustado
P_w

⟶

SEMANA w+1
Fechamento P_{w+1}

$$R_w^{(1)} = \ln\left(P_{w+1}/P_w\right)$$

Sexta feriado?
Último pregão na quinta;
corte na quarta à noite.

Exemplo de calendário · w: semana · R: retorno logarítmico futuro

Dissertação, §4.6, Eq. iti-retorno

Cem notícias formam um diagnóstico exploratório

100

notícias documentais

Aspecto	Condição
Seleção	Não aleatória; apoiada em classes previstas
Referência	Autor · protocolo de 07/10/2026
Conteúdo	Em 15 registros, repete o título
Validação independente	Ainda pendente

As métricas descrevem esta amostra; não estimam todo o corpus temporal.

Dissertação, §4.3 e §5.1.1

A matriz revela os padrões de discordância

Linhas: autor · Colunas: modelo · Unidade: notícia

Autor / Modelo	Negativa	Neutra	Positiva
Negativa	13	1	0
Neutra	21	32	14
Positiva	4	10	5

50 / 100 na diagonal

35 das 67 notícias neutras da referência receberam previsão com polaridade (21+14)

Desacordo com a referência individual não é prova isolada de erro do modelo.

Dissertação, §5.1.1, tabela confusao-100

Acurácia isolada favorece a classe majoritária



Classe	Referência	F1
Negativa	14	0,500
Neutra	67	0,582
Positiva	19	0,263

F1 macro: 0,448 · Kappa: 0,197

Sempre prever neutro acerta 67 casos, mas não reconhece as outras classes.

Dissertação, §5.1.1, tabelas avaliacao-texto e metricas-classe-100

O diagnóstico documental não valida o recorte do ITI

AVALIADO

Título + conteúdo disponível
100 pares de classes
Concordância: 50%

UTILIZADO NO ITI

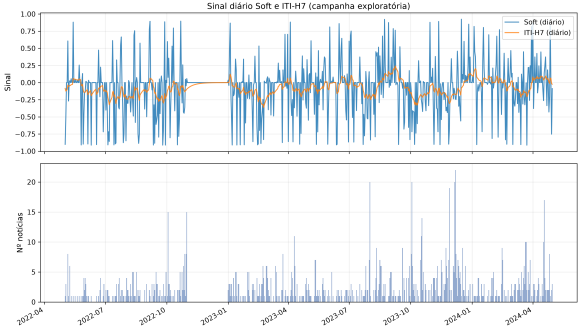
Trechos próximos à Sabesp
Probabilidades contextuais
Validação independente pendente

Próxima avaliação: mesmas notícias, duas entradas e referência independente.

Dissertação, §4.4 e §5.1.2

As séries mostram a persistência produzida pelo ITI

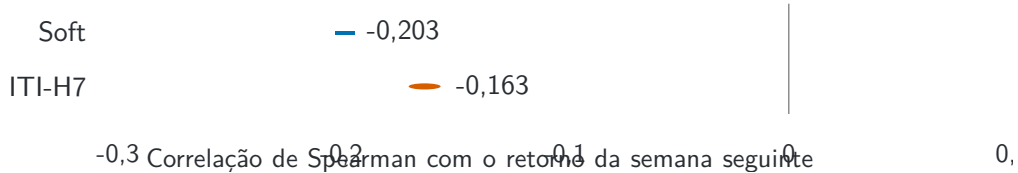
Soft diário: azul · ITI-H7 diário: laranja



Séries observadas · suavidade não demonstra capacidade preditiva.
Dissertação, §5.2.3, figura iti-campanha-1

O ITI tem correlação de menor magnitude absoluta

104 semanas alinhadas - 10 de aquecimento = 94 semanas



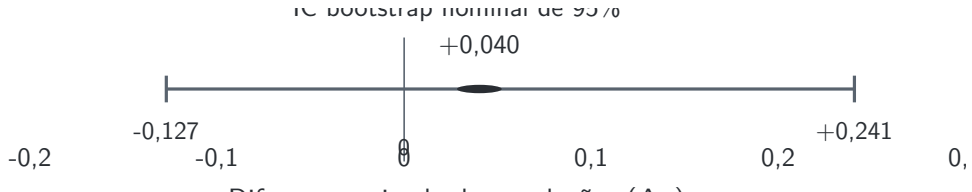
$$\Delta\rho = (-0{,}163) - (-0{,}203) = +0{,}040$$

Mais próximo de zero = menor magnitude absoluta.

Dissertação, §5.2.1, tabela iti-primary

O intervalo da diferença atravessa zero

Bootstrap em blocos: 4 semanas · 10.000 reamostragens pareadas



p exploratório = 0,512 · sem distribuição nula explicitamente construída

Resultado inconclusivo: não demonstra superioridade nem equivalência.

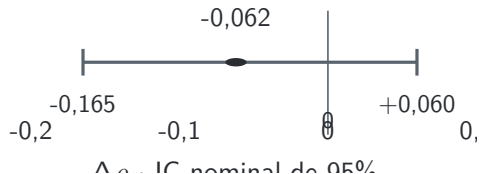
Dissertação, §4.5 e §5.2.1, tabela iti-primary

Zero no corte não significa uma semana sem notícias

36 de 94 semanas com Soft = 0 no corte

Em 33 dessas 36, havia notícia anterior na janela semanal.

ITI-H7 - média semanal



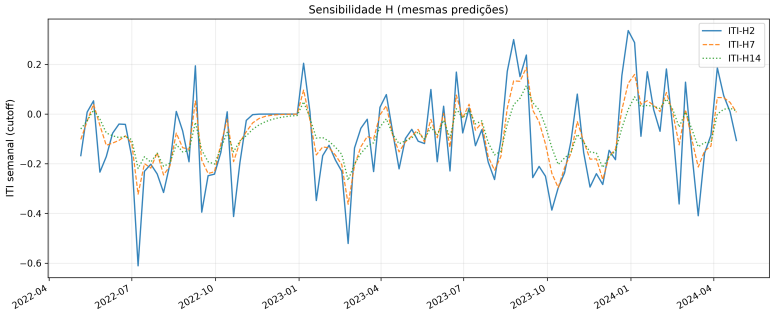
p exploratório = 0,340

Comparação complementar ainda muda janela e pesos ao mesmo tempo.

Dissertação, §5.2.4, tabela contrastes-baselines

A meia-vida controla a velocidade de resposta

H=2: azul contínuo · H=7: laranja tracejado · H=14: verde pontilhado



H=7 é a configuração principal; não foi demonstrado como ótimo.

Dissertação, §5.2.3, figura iti-campanha-2

As limitações definem o próximo experimento

Dimensão	Limitação	Encaminhamento
Construto	Recorte sem referência independente	Avaliar as duas entradas
Comparabilidade	Histórico e pesos variam juntos	Fixar a janela; variar pesos
Cobertura e reprodução	Lacunas e versões incompletas	Preservar dados e registros
Inferência e escopo	94 semanas; caso Sabesp	Protocolo fixo e período novo

Associação exploratória não demonstra previsão, causalidade ou generalização.

Dissertação, §5.3, tabela ameacas

Cinco etapas para consolidar a dissertação



Prazos indicativos após a qualificação; conclusão não depende de significância.

Dissertação, §6.2, tabela plano-continuidade

Procedimento implementado; validação em continuidade

IMPLEMENTADO	Notícias → probabilidades → escores → ITI → alinhamento
EVIDÊNCIA	Diagnóstico textual e contrastes temporais exploratórios
CONTINUIDADE	Validar entradas e comparar pesos sob a mesma janela

Obrigado. Perguntas e contribuições da banca são bem-vindas.

Dissertação, §6.1

Ficha técnica da campanha temporal

Parâmetro	Registro
Caso e período	Sabesp / SBSP3 · maio/2022 a abril/2024
Corpus	1.253 notícias canônicas · 5 fontes
Classificador	lucas-leme/FinBERT-PT-BR · limite: 512 tokens
Entrada temporal	Menção à Sabesp e até 1 vizinha por lado
Meia-vida	7 dias civis; sensibilidades: 2 e 14
Aquecimento e painel	70 dias · 104 semanas alinhadas · 94 no contraste
Reamostragem	10.000 réplicas · blocos de 4 semanas

Dissertação, §4.4–4.7; Apêndice B, tabela rastreabilidade

Métricas por classe no diagnóstico documental

Classe	Precisão	Revocação	F1	Suporte
Negativa	0,342	0,929	0,500	14
Neutra	0,744	0,478	0,582	67
Positiva	0,263	0,263	0,263	19
Média macro	0,450	0,556	0,448	100

Precisão: acertos entre as previsões da classe.
Revocação: exemplos da classe recuperados. Suporte: quantidade na referência.

Dissertação, §5.1.1, tabela metricas-classe-100

Oito sensibilidades permanecem exploratórias

Comparação	$\Delta\rho$	IC inf.	IC sup.	p Holm
H=2 - Soft	+0,067	-0,081	+0,236	1,000
H=14 - Soft	+0,035	-0,135	+0,245	1,000
ITI-H7 - Soft · Pearson	+0,038	-0,127	+0,224	1,000
ITI-H7 - Soft · 2 semanas	-0,103	-0,296	+0,150	1,000
ITI-H7 - Soft · 4 semanas	-0,177	-0,368	+0,084	1,000
ITI-H7 - escore discreto	-0,078	-0,337	+0,275	1,000
Recorte contextual - integral	-0,061	-0,195	-0,013	0,200
ITI-H7 - suavização alternativa	-0,031	-0,078	+0,079	1,000

Holm ajusta os valores p da família; os intervalos continuam nominais.

Dissertação, §5.2.2, tabela iti-secondary

Os grupos heurísticos têm composições diferentes

Grupo	n	Acurácia	Kappa	F1 macro
Completo	100	50,0%	0,197	0,448
Focal (heurística)	74	52,7%	0,260	0,498
Agenda/multiempresa	26	42,3%	-0,032	0,204

Grupo agenda: 24 neutras, 2 positivas e nenhuma negativa na referência.
A diferença é descritiva; não isola o efeito do tipo de notícia.

Dissertação, §5.1.1 e §5.1.3, tabela avaliacao-texto

Bootstrap: reamostrar semanas mantendo o pareamento

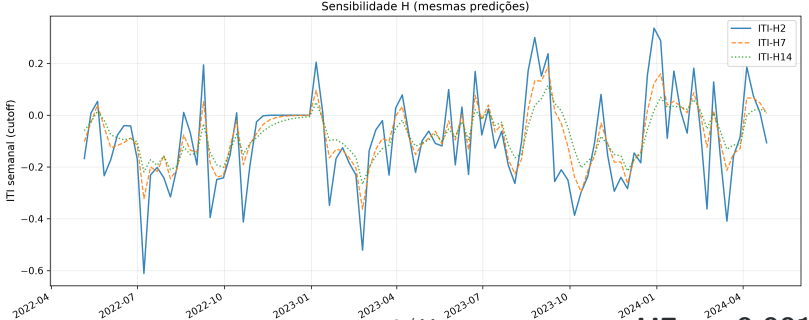
Passo	Operação
1 · Unidade	Semana com ITI, referência e retorno juntos
2 · Bloco	Selecionar 4 semanas contíguas; respeitar lacunas
3 · Réplica	Reamostrar blocos e recalcular a diferença
4 · Repetição	10.000 réplicas; IC nos percentis 2,5 e 97,5

p exploratório: duas vezes a proporção no lado oposto ao sinal observado, limitado a 1. Não é uma distribuição nula explícita.

Dissertação, §4.5, parágrafo Contraste e incerteza; Künsch (1989)

H controla a persistência; o aquecimento também importa

H2: azul contínuo · H7: laranja tracejado · H14: verde pontilhado



Peso inicial após 70 dias $= 2^{-70/H}$

H7: $\approx$ 0,001
H14: 0,03125

Dissertação, §4.5 e Apêndice C; figura iti-campanha-2

Experimento futuro: mesma janela, pesos diferentes

Fixar antes do teste: janela, dias elegíveis, escores e corte.

$$U_w = \frac{1}{m} \sum_{j=0}^{m-1} X_{d_w - j} \qquad E_w = \frac{\sum_{j=0}^{m-1} \lambda_H^j X_{d_w - j}}{\sum_{j=0}^{m-1} \lambda_H^j}$$

m: número de dias da janela · d_w: dia de corte · j: idade em dias
U_w: agregação uniforme · E_w: exponencial normalizada · X: entrada diária

Planejado: E_w tem janela finita; não é a recorrência histórica do ITI.
Dissertação, §6.2

Referências que sustentam os componentes

Santos, Bianchi e Costa (2023)
FinBERT-PT-BR
10.5753/bwaif.2023.231151

Cortis et al. (2017)
SemEval-2017 Task 5
10.18653/v1/S17-2089

Sinha et al. (2022)
SEntFiN 1.0
10.1002/asi.24634

Tang et al. (2023)
FinEntity
10.18653/v1/2023.emnlp-main.956

Shapiro, Sudhof e Wilson (2022)
Measuring News Sentiment
10.1016/j.jeconom.2020.07.053

Buckman et al. (2020)
News Sentiment in the Time of COVID-19
FRBSF Economic Letter 2020-08

Künsch (1989)
Bootstrap em séries
10.1214/aos/1176347265

Holm (1979)
Comparações múltiplas
Scand. J. Stat. 6(2), 65–70

Fundamentos dos componentes; não prova de H=7 ou superioridade.
Dissertação: bibliografia e caps. 2–3.