

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

LUIZ FERNANDO MENEGAZZO FERREYRA

**OS IMPACTOS DE NOTÍCIAS NA PERFORMANCE DAS AÇÕES DE EMPRESAS
DE CAPITAL ABERTO NO BRASIL**

LONDRINA

2025

LUIZ FERNANDO MENEGAZZO FERREYRA

**OS IMPACTOS DE NOTÍCIAS NA PERFORMANCE DAS AÇÕES DE EMPRESAS
DE CAPITAL ABERTO NO BRASIL**

**The impact of news on share performance of publicly traded companies in
Brazil**

Trabalho de conclusão de curso de graduação
apresentado como requisito para obtenção do título
de Bacharel em Engenharia de Produção do Curso
da Universidade Tecnológica Federal do Paraná
(UTFPR).

Orientador: Bruno Samways dos Santos.

LONDRINA

2025



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

LUIZ FERNANDO MENEGAZZO FERREYRA

**OS IMPACTOS DE NOTÍCIAS NA PERFORMANCE DAS AÇÕES DE EMPRESAS DE
CAPITAL ABERTO NO BRASIL**

Trabalho de conclusão de curso de graduação
apresentado como requisito para obtenção do título
de Bacharel em Engenharia de Produção do Curso
da Universidade Tecnológica Federal do Paraná
(UTFPR).

Orientador: Bruno Samways dos Santos.

Data de aprovação: 17/novembro/2025

Bruno Samways dos Santos

Doutorado

Universidade Tecnológica Federal do Paraná

Rafael Henrique Palma Lima

Doutorado

Universidade Tecnológica Federal do Paraná

Pedro Rochavetz de Lara Andrade

Doutorado

Universidade Tecnológica Federal do Paraná

LONDRINA

2025

AGRADECIMENTOS

Eu gostaria de expressar gratidão ao Prof. Dr. Bruno Samways dos Santos, que me orientou durante todo o processo de criação deste trabalho, contribuindo para o meu desenvolvimento acadêmico.

Além disso, também agradeço à minha família, que me apoiou durante todo o desenrolar do curso de Engenharia de Produção, me dando suporte quando necessário.

Ademais, eu também agradeço ao Grupo de Pesquisa em Otimização e Mineração de Dados - GPOMD, que me auxiliou com ideias e discussões enriquecedoras sobre dados e algoritmos.

Por fim, gostaria de agradecer aos meus colegas de classe pelos momentos passados juntos durante o curso.

RESUMO

O mercado financeiro é reconhecido pela sua dinamicidade, com informações publicadas sendo repassadas de maneira quase instantânea aos preços dos ativos negociados em bolsa. Com o avanço das publicações em meio digital, o acompanhamento de notícias que podem influenciar a performance de ações negociadas em bolsa se mostra como um campo de alta relevância para estudos com a temática de mercado financeiro. Assim, o objetivo deste estudo é verificar a existência de uma relação de causalidade entre o sentimento atual de portais de notícias especializados no mercado financeiro e o desempenho futuro de ações na bolsa de valores, aplicando um modelo baseado em *Bidirectional Encoder Representations from Transformers*, BERT, para classificação dos sentimentos de publicações online. Com este trabalho, foi possível identificar uma falta de causalidade entre as duas variáveis investigadas, com cinco das sete previsões de performance de ações feitas não apresentando retorno positivo, mas, devido ao modo como foi desenvolvido a aplicação do algoritmo de tratamento e correlação entre os dados, além da geração de recomendações de alocação de investimento, este estudo contribuiu para futuras pesquisas acadêmicas nesta área ao sugerir inúmeros caminhos para a busca de resultados melhores e outras hipóteses de relações de causalidade entre variáveis envolvidas no problema. Além disso, a validação do modelo *FinBERT* para a análise de sentimentos e a orientação acerca de palavras mais associadas com sentimentos positivos e negativos podem auxiliar pesquisas futuras e profissionais que estejam buscando por aplicações para a comunicação empresarial.

Palavras-chave: Mineração textual; Análise de sentimentos; Carteira de investimentos.

ABSTRACT

The financial market is known for its dynamism, with newly published information being transmitted almost instantly to the prices of assets traded on the stock exchange. With the growth of digital publications, monitoring news that may influence the performance of publicly traded stocks has become a highly relevant field of study within financial markets. Thus, the aim of this study is to examine the existence of a causal relationship between the current sentiment expressed by financial news portals and the future performance of stocks in the market, through the application of a BERT-based model for sentiment classification of online publications. The findings indicate an absence of causality between the two variables investigated, as five out of seven stock performance predictions did not yield positive returns. However, due to the structure of the data-processing algorithm, the correlation procedures adopted, and the generation of investment allocation recommendations, this research contributes to future academic work in the field by suggesting several avenues for achieving improved results and for suggesting other potential causal relationships among the variables involved in the problem. Furthermore, the validation of the FinBERT model for sentiment analysis, as well as the identification of words most associated with positive and negative sentiments, may support subsequent studies and benefit professionals seeking applications in corporate communication.

Keywords: Text mining; Sentiment analysis; Investment portfolio.

SUMÁRIO

1. INTRODUÇÃO	5
2. FUNDAMENTAÇÃO TEÓRICA	8
2.1 Processamento de Linguagem Natural	8
2.1.1 Técnicas de interpretação da linguagem	9
2.2 Análise de sentimentos	10
2.2.1 Principais objetivos	10
2.2.2 Processamento de dados	11
2.2.3 <i>Transformers</i> , RoBERTa e desafios	12
2.3 Mercado financeiro	13
2.3.1 Mercado financeiro brasileiro	14
2.3.2 Análises qualitativas, quantitativas e técnicas	15
2.3.3 Impacto midiático no mercado	17
2.4 Trabalhos correlatos.....	18
3. METODOLOGIA	20
3.1 Bibliotecas e ferramentas utilizadas	20
3.2 Criação do Conjunto de Dados.....	21
3.3 Sequência de Execução	23
4. RESULTADOS E DISCUSSÃO	29
4.1 Exploração de dados	29
4.2 Análise da aplicação	33
4.3 Limitações e sugestões para futuros trabalhos.....	36
5. CONCLUSÃO	39
BIBLIOGRAFIA	40

1. INTRODUÇÃO

Desde a criação dos mecanismos computacionais, o ser humano busca desenvolver um meio automatizado que compreenda o texto escrito e realize alguma atividade com este entendimento (ZHU, 2021). Com estes objetivos, em meados do século XX foi dado início às primeiras tentativas de criação de mecanismos de tradução entre diferentes linguagens humanas, encontrando dificuldades sobretudo com a mudança exercida sobre o significado pelo contexto em que certa palavra era inserida. De acordo com Hutchins (2007), esta dificuldade em particular demonstrou o porquê de uma simples tabela de conversão direta, representada pela ideia de dicionários mecânicos, entre palavras de diferentes linguagens não resultar em uma tradução acurada.

Assim, com o avanço da computação, surgiram modelos que compreendessem a linguagem humana com maior precisão. Para ampliar o papel do contexto na interpretação linguística de um algoritmo, foram criados programas que considerassem os vizinhos de cada palavra, assim como seus múltiplos significados, permitindo um entendimento majorado pelo algoritmo (HUTCHINS, 1995). Atualmente, os algoritmos mais avançados utilizam o cálculo matricial para relacionar uma palavra com todo o restante do texto, bem como a orientação de seu posicionamento (LIU et al., 2019), sendo treinados por extensas bases de dados para permitir uma boa compreensão da linguagem humana, seu significado e os sentimentos por ela expressos.

Ao atingir um nível de acurácia alto para a interpretação da linguagem humana e seus sentimentos, estes modelos permitiram o surgimento de novas aplicações do entendimento da linguagem nas mais diversas áreas. Além da tradução, comentada anteriormente, a análise do sentimento predominante em *posts* de redes sociais e notícias jornalísticas é amplamente utilizada para os mais diversos fins, possibilitando a identificação de padrões de comportamento e pensamento da população (DRUS; KHALID, 2019).

Dentre os usos para a análise de sentimentos, há a tentativa de entender a influência exercida no desempenho de índices e ações de empresas no mercado financeiro pelo sentimento dominante no público e na mídia, o que tem ganhado destaque com o avanço de pesquisas na área de finanças comportamentais (YU;

DUAN; CAO, 2013). Esta compreensão é particularmente relevante pois é essencial que tanto os integrantes da alta administração de companhias com ações negociadas em bolsa como também investidores e administradores de fundos de investimento entendam não só as melhores formas de comunicar um fato ocorrido, mas também compreendam o impacto dos comunicados de sua empresa no mercado acionário desde o curto até o longo prazo.

Dessa forma, este trabalho avaliou, por meio da mineração textual e posterior avaliação do sentimento predominante na amostra, a possibilidade de existência de uma relação de causalidade entre o viés de notícias online acerca de empresas de capital aberto no Brasil, e o desempenho de suas ações na bolsa de valores em diferentes prazos após a publicação do material jornalístico. Dentro deste campo, este trabalho focalizou empresas com alto valor de mercado, que possuíssem um grande volume de notícias específicas, buscando dados de portais jornalísticos relevantes para a área.

Para atingir este objetivo, foi feito um referencial teórico acerca dos algoritmos de processamento de linguagem e de análise de sentimentos, além de uma busca sobre estudos que correlacionam esta área com aplicações no mercado financeiro, seja nacional ou estrangeiro. Este referencial validou a escolha de um método de análise de sentimentos (especificamente, uma biblioteca baseada no modelo BERT adaptada ao mercado financeiro), o qual permitiu que as notícias fossem compreendidas de forma satisfatória e automática, melhor quando comparado a outros meios de análise. Por fim, também foram sugeridas formas de melhorar o uso da extração de dados da web conjunta à análise de sentimentos para a melhor acurácia do algoritmo final.

Levando a possibilidade da alocação de investimentos baseada em notícias de jornais online (MCINDOE, 2018), essa pesquisa justifica-se por trazer a aplicação de um algoritmo de análise de sentimentos para entender a correlação da performance de ações de grandes empresas brasileiras e a aparição das mesmas em textos jornalísticos online especializados no mercado financeiro. Assim, foram sugeridas formas de melhorar a comunicação empresarial, buscando evitar que erros de compreensão venham a ocasionar volatilidade desnecessária.

Evitando erros de compreensão entre o mercado financeiro e a empresa, serão evitadas falhas de comunicação por parte da alta gestão que resultem em perdas financeiras aos investidores e consequente perda de credibilidade da empresa no

mercado acionário. Além disso, com os resultados deste estudo, será possível tanto para o leitor especializado como para as companhias compreender melhor o impacto das operações de transmissão de informação no retorno das ações na bolsa de valores, dúvida que ganha cada vez mais importância através do avanço das mídias digitais.

2. FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a fundamentação teórica que serve de alicerce para o presente trabalho. A abordagem partirá do campo mais amplo do Processamento de Linguagem Natural (PLN), explorando seus marcos históricos e principais técnicas empregadas a fim de contextualizar esta área de estudo. Em sequência, será aprofundado o conceito de mineração de dados (*Data Mining*), detalhando os mais importantes processos de obtenção de dados pela via *online*, além de barreiras e implicações éticas destes mecanismos.

Esta seção segue com o estudo da análise de sentimentos, investigando também seu histórico, funcionamento e paradigmas da atualidade, buscando interligar seus conceitos com sua importância para este presente trabalho. Por fim, o capítulo converge para o mercado financeiro, área essencial desta pesquisa, detalhando seus fundamentos, tanto a nível nacional quanto global, análises intrínsecas a este campo e a importância desta pesquisa para a área.

2.1 Processamento de Linguagem Natural

O PLN (Processamento de Linguagem Natural) pode ser definido como uma área que busca compreender a linguagem humana através de algoritmos computacionais, aplicando este reconhecimento da linguagem em campos variados (CHOWDHARY, 2020). Como exemplo, o uso da PLN aumentou de forma significativa nas últimas décadas com a expansão da disponibilidade de databases de linguagens e do também aumento da capacidade computacional (BEYSOLOW, 2018). Ambos acontecimentos propiciaram o desenvolvimento de algoritmos de inteligência artificial que utilizam PLN para transformar um comando feito de linguagem humana em comandos computacionais.

Ademais, o problema de entendimento da linguagem humana, apesar de evocar uma certa simplicidade devido à nossa vivência cotidiana em sociedade, é considerado complexo para uma máquina. Inicialmente, o computador necessita obter o conhecimento morfológico da palavra, compreendendo seu significado particular, partindo para a compreensão do seu contexto de uso na sentença, e por fim ligando

este entendimento com o ambiente de uso no texto (CHOWDHARY, 2020), garantindo que a compreensão aconteça nos mais diversos usos do vocabulário.

Assim, para o seguimento deste trabalho, foi considerada importante a descrição das suas principais técnicas empregadas atualmente na indústria digital. Assim, os próximos tópicos serão destinados ao retrato destes pontos, auxiliando na compreensão da complexidade do problema estudado pelo trabalho e das maneiras escolhidas para sua resolução.

2.1.1 Técnicas de interpretação da linguagem

O PLN, como visto na seção anterior, passou por muitas variações ao longo da história, ainda possuindo diferentes métodos de ser executado. A efetividade de cada uma destas maneiras varia bastante de acordo com as características do problema em questão que deve ser resolvido, com variáveis como o formato de texto, a coerência gramatical, e até mesmo a língua, influenciando na qualidade do processamento.

Dessa forma, serão vistas algumas das principais técnicas de interpretação de linguagem da atualidade, iniciando pela tokenização. Este processo é feito a partir da divisão do texto, tipicamente palavras e caracteres especiais, em *tokens*, com a maior dificuldade sendo decisões que incluam palavras com apóstrofes ou outros símbolos especiais (PINTO; OLIVEIRA; ALVES, 2016). Dentre as diversas técnicas de tokenização já disponíveis, uma que se destaca é o *OpenNLP Tokenizer*, que segundo (HE; KAYAALP, 2006) deixa à disposição do usuário um modelo capaz de ser treinado tanto por um conjunto de dados próprio, como também por um próprio do sistema.

Em sequência, os campos aleatórios condicionais, ou do inglês *conditional random fiels* (CRFs) na sigla em inglês, são muito usados no processamento de linguagem natural através de sua forma linear. Os CRFs funcionam a partir da discriminação de probabilidades estatísticas, moldando a dependência entre os *tokens* de uma frase (DUPONT, 2018). Por meio desse modelo, é possível averiguar o contexto de certa frase, analisando melhor seu significado.

Ademais, algoritmos de *Part-of-speech tagging*, ou *POS tagging*, tem como objetivo marcar os *tokens* anteriormente criados com *tags* de acordo com suas funções morfosintáticas no texto (ORPHANOS et al., 1999). Dessa maneira, o algoritmo de avaliação de texto consegue trabalhar em cima de dados estruturados,

permitindo-o chegar a conclusões utilizando de técnicas de inteligência computacional já normais a outros problemas.

Por fim, com o avanço das técnicas que utilizam *transformers* para avaliação textual, ferramentas como a *Hugging Face Transformers* tem se tornado padrão para trabalhos na área (ROTHMAN, 2022). Devido a facilidade de uso desta biblioteca, permitindo o acesso à modelos avançados, o resultado tem sido a aceleração de pesquisas que utilizem PLN.

2.2 Análise de sentimentos

Definida como um conjunto de técnicas de estruturação automática de bases de dados com informações subjetivas advindas de textos de linguagem natural (BENEVENUTO; RIBEIRO; ARAÚJO, 2015), a análise de sentimentos possui a capacidade de possibilitar o entendimento de positividade ou negatividade de um texto por uma máquina, conseguindo assim identificar a expressividade e, logo, o sentimento do autor de um texto com o uso de algoritmos.

As subseções a seguir discutem os principais objetivos para o uso da análise de sentimentos, incluindo as suas aplicações principais, e como este tópico está intrinsecamente ligado ao tópico desta pesquisa. Em seguida, foram vistas as técnicas mais utilizadas para a análise de sentimentos na atualidade, assim como as mais correlacionadas com o tema da pesquisa. Por fim, viu-se os principais desafios e limitações relacionados a esta tecnologia e como estes impactam pesquisas similares.

2.2.1 Principais objetivos

Com o avanço da era digital, o mundo online se tornou palco para grande parte da população expressar seus sentimentos e opiniões acerca de fatos e acontecimentos diários. Entendendo a importância desta nova fonte de informação, é cada vez maior o número de empresários que buscam analisar estes dados gerados pelo mercado consumidor de seus produtos e serviços (SALUSTIANO, 2016). Dentre as diversas formas de trabalhar com estes dados, a análise de sentimentos agrega valor pelo entendimento de opiniões de certo texto, ligando-as com o sujeito e, assim, identificando visões positivas e negativas acerca de um determinado assunto.

Em Nascimento, Osiek e Xexéo (2015), foi feita uma análise de interpretação dos sentimentos de usuários de uma rede social, acerca de assuntos relacionados à entretenimento, política e temas policiais, obtendo resultados satisfatórios de identificação automática de sentimentos dos textos das duas últimas categorias. Este exemplo, já profundamente estudado em diversas pesquisas, demonstra a capacidade de identificação automática de sentimentos por algoritmos da área, refletindo o potencial de uso para gestão empresarial. Mais adiante, os casos de falha, representados pela primeira categoria de *posts* analisados pelos pesquisadores, e as limitações destes algoritmos serão discutidas, assim como meios de contorná-los.

2.2.2 Processamento de dados

O Processamento de Linguagem Natural é uma peça chave na Análise de Sentimentos, auxiliando na segmentação e entendimento léxico do texto para aplicação do algoritmo de *Opinion Mining* (GOMES, 2013). Apesar disto, algumas técnicas de PLN, como traduções de texto e correções de ortografia não são aplicadas em conjunto à Análise de Sentimentos para evitar-se distorções do texto original e, logo, o apagamento dos sentimentos pretendidos pelo autor original.

É esperado que, devido ao grande volume de dados disponíveis atualmente na internet, várias ferramentas diferentes de análise de sentimentos estejam disponíveis para atender aos requisitos que cada formato de linguagem impõem. Dessa forma, é interessante citar algoritmos muito utilizados para a análise de textos de redes sociais, muito comuns nos dias atuais.

Primeiramente, a linguagem de emoticons oferece um jeito simples de identificar o sentimento de uma mensagem, com cada emoji estando diretamente relacionado a um sentimento previamente descrito (ARAÚJO et al., 2013). Além disso, o uso de métodos de *lemmatization*, através de plataformas como a Amazon Comprehend, já foram testadas para analisar sentimentos em notícias (IGARASHI; VALDEVIESO; IGARASHI, 2021).

Em sequência, é importante ressaltar que modelos de avaliação de sentimentos como o RoBERTa ofereceram bons resultados quando testados com em *fine-tuning* conjuntamente a um modelo de dados (JUNIOR, 2021). Este modelo oferece uma leitura de sentimentos para textos formais e informais, retornando um score com base no sentimento aferido já com a língua portuguesa (OJEDA;

ZALEWSKI; MALETZKE, 2024), indo ao encontro das demandas computacionais desta pesquisa.

2.2.3 Transformers, RoBERTa e desafios

Muitos dos modelos mais utilizados para a análise de sentimentos, até a década passada, apresentavam o funcionamento baseado sobretudo no sequenciamento de tokens, demandando uma capacidade computacional proporcional ao tamanho do *input*. Surgidos na década de 80, estes algoritmos, e.g. RNN e LSTM, mostraram bastantes desafios ao não serem computacionalmente eficientes com textos longos, apresentando uma limitação de aplicações (ROTHMAN, 2021).

Nos anos recentes, a criação do mecanismo de *Transformers* permitiu que textos fossem lidos de uma forma mais eficiente, em que operações entre matrizes possibilitam uma busca por correlações entre tokens independentemente da ordem (VASWANI et al., 2017). Esta mudança apoiou-se na arquitetura massivamente paralela dos sistemas GPUs, chamada de *manycore*, que entrega uma maior capacidade computacional para a realização de operações similares simultaneamente (RIOS et al., 2016).

Fazendo uso desta inovação, o modelo BERT (*Bidirectional Encoder Representation from Transformers*), já possui um pré-treinamento, fazendo o reconhecimento bidirecional dos tokens e aumentando assim o reconhecimento do significado de um texto (AFTAN; SHAH, 2023). Atualmente, este modelo é amplamente utilizado por pesquisadores, entregando um desempenho superior aos demais mecanismos.

Como um refinamento do modelo BERT para uso na análise de sentimentos, o modelo de classificação de linguagem RoBERTa, ou *Robustly Optimized BERT Approach*, entrega melhorias nos quesitos de treinamento auxiliar e tamanho do conjunto de dados de pré-treinamento (COIMBRA et al., 2023). Comparando o modelo RoBERTa com outros modelos pré-treinados, Adoma, Henry e Chen (2020) verificaram que este obteve a maior acurácia para a classificação de textos entre sete sentimentos diferentes, sendo um dos modelos considerados apropriados para utilização em pesquisas semelhantes a esta.

Apesar de sua superioridade se comparado a modelos similares, o RoBERTa possui algumas limitações envolvendo sobretudo o seu treinamento e suas funcionalidades (RAY, 2023). Primeiramente, devido à sua complexidade, sua forma de cálculo não é de fácil interpretação, com o seu treinamento também requisitando uma alta capacidade computacional. Além disso, caso seja necessário treinar o modelo para alguma atividade específica, uma grande quantidade de dados de alta qualidade é necessária. Por fim, por ter sido treinado majoritariamente em inglês, o uso do RoBERTa em textos de outras línguas pode não entregar resultados tão bons quanto em sua língua materna, com a linguagem FinBERT treinada em português resolvendo este entrave.

2.3 Mercado financeiro

O mercado financeiro é o meio pelo qual diferentes partes, denominadas de investidores, podem realizar transações de ativos, e.g. dinheiro, e obter participações em empresas e títulos governamentais, abrangendo uma grande variedade de segmentos e produtos financeiros disponíveis. Para proporcionar um ambiente que possibilite que estas trocas ocorram, o mercado financeiro deve dispor de transparência na difusão de informações, incluindo o preço dos ativos, além de conter regras básicas para negociações, custos e taxas (KUMAR, 2014).

Para se referir aos títulos de participação no capital de empresas, o termo normalmente utilizado no mercado financeiro, que também será utilizado nesta pesquisa, é “ação”, do inglês *stock* (TEWELES; BRADLEY, 1998). Estes títulos, para empresas de capital aberto, são publicamente negociados em instituições denominadas bolsas de valores, tipicamente formadas quando há uma alta demanda por corretores que realizem a intermediação entre as partes compradora e vendedora de um ativo (MICHIE, 2001).

Os analistas de mercado, responsáveis por entender os ativos negociados em bolsas de valores e calcular a sua precificação teoricamente ideal, também possuem grande relevância como participantes ativos do mercado financeiro. Dessa forma, empresas que explicitam suas informações de uma maneira adequada são mais facilmente compreendidas pelos analistas, que realizam previsões de seus resultados mais coerentes com a realidade (WANG et al., 2024).

A partir deste ponto, deduz-se que as ações de uma empresa com bons resultados operacionais podem sofrer perdas na bolsa de valores devido a previsões financeiras destoantes da realidade feitas pelo mercado. Dessa forma, a fim de evitar que tais interpretações errôneas ocorram, é de responsabilidade da empresa realizar uma comunicação clara de modo a elucidar aos analistas sua situação real. Assim, este tópico buscará explicar as particularidades do mercado financeiro brasileiro e os impactos da comunicação nas análises que, por sua vez, dirigem os preços de ações na bolsa de valores.


2.3.1 Mercado financeiro brasileiro

As negociações de ativos em bolsas de valores no Brasil tiveram início durante o período do império, com a criação da Bolsa de Valores do Rio de Janeiro. No final do século XIX, foi criada a primeira bolsa de valores de São Paulo, que após mais de um século de história, mudando de nome algumas vezes, tornou-se a BM&F BOVESPA (SELAN, 2015). Atualmente denominada B3, esta companhia representa a única bolsa de valores presente no Brasil no tempo desta pesquisa.

Dentre as diversas empresas com capital aberto na bolsa de valores do Brasil, as que possuem maior relevância em termos de volume de negociação são normalmente escolhidas para compor o Ibovespa, o principal índice do mercado brasileiro. Com uma grande amplitude de setores e empresas, este índice acaba refletindo o desempenho da economia nacional, podendo ser utilizado para analisar a tendência do mercado como um todo (JALE, 2019).

Por sua característica flexível e volátil, a composição e participação das empresas no Ibovespa frequentemente se altera, entretanto é possível verificar momentaneamente o peso de determinados setores na composição do índice. Em abril de 2025, segundo B3 (2025), os setores com participação acima de 10% no Ibovespa incluíam serviços financeiros e de utilidade pública além de produtores de commodities. O gráfico da Figura 1, elaborado a partir de dados da B3, traz a participação percentual dos setores de cada uma das empresas presentes no índice, com as categorização advindas diretamente da bolsa de valores.

Figura 1 - Representação percentual de cada setor no Ibovespa B3



Fonte: B3 (2025), adaptado pelo autor (2025)

Outra característica dos mercados de ações é a influência no desempenho destes por agentes políticos e econômicos, com o mercado brasileiro não sendo uma exceção à regra. Dessa forma, segundo Grôppo (2006), o incremento da taxa de câmbio, assim como das taxas de juros de curto e longo prazo, respectivamente Selic e TJLP, podem afetar negativamente os ativos da bolsa brasileira. Além destes indicadores, a inflação, também afetada pela política monetária, possui um efeito negativo nas ações do Ibovespa (SOARES; FIRME; JÚNIOR, 2021).

O caso brasileiro, em especial, demonstra que as decisões e modelos políticos possuem grande influência na inflação, crescimento econômico e produtividade histórica da economia do país (FRANCO, 1998). Dessa forma, visto que estas variáveis afetam o desempenho do índice acionário brasileiro, é possível afirmar que decisões políticas e monetárias podem afetar o retorno das ações no Brasil, o que vai além de notícias intrínsecas às próprias empresas.

2.3.2 Análises qualitativas, quantitativas e técnicas

Para a realização de análises de dados e evidências, duas abordagens possuem maior consolidação, sendo elas análises quantitativas e qualitativas. Para o desenvolvimento das análises quantitativas, é realizado o estudo de variáveis

numéricas, buscando encontrar relações implícitas que entreguem alguma interpretação relevante (NEVIN, 1984). No mercado financeiro, podem ser efetuadas análises quantitativas técnicas, que levam em conta a movimentação recente dos mercados para realização de previsões futuras, e análises fundamentalistas, que se utilizam de dados financeiros para avaliar as possibilidades de retorno de um ativo (SHARMA; KAUSHIK, 2018). Nestes casos, podem ser utilizados diversos algoritmos de *machine learning* para se avaliar as informações quantificáveis.

Quanto à análise qualitativa, sua principal característica é a interpretação e qualificação de informações subjetivas, o que, feito de forma manual, oferece problemas de contaminação por viés, baixa replicabilidade e lentidão no processamento de informações. Para estes desafios, os algoritmos de PLN podem oferecer soluções como automação, impessoalidade e replicação da interpretação de informações (LEESON et al., 2019), com estas qualidades também podendo ser aplicadas à geração de dados quantificáveis a partir de textos jornalísticos subjetivos.

Para a análise de notícias, um dos problemas mais comumente encontrados é a interpretação da linguagem por algoritmos em tempo suficiente para realizar investimentos, visto que o mercado tende a sempre buscar o preço correto em tempo real. Ainda assim, o PLN pode ser aplicado para identificar termos reportados que levem a flutuações atípicas no preço de um ativo, beneficiando quem o usar com uma vantagem de tempo e melhores oportunidades de entendimento da situação atual (SCHUMAKER; CHEN, 2009), levando ao maior embasamento de decisões para a alocação de patrimônio.

É relevante que seja também discutido o momento de captura dos dados de performance dos ativos analisados, com uma tendência pré-existente de baixa ou de alta no preço do ativo interferindo no retorno posterior à influência do meio midiático (LI et al., 2014). Dessa forma, é possível verificar se houve algum impacto real no retorno do ativo após a divulgação da informação, mensurando-o por meio de uma análise quantitativa dos dados disponibilizados pelo mercado.

Ademais, a análise técnica é o estudo dos padrões gráficos de ativos negociados no mercado financeiro, buscando determinar a direção dos preços em algum momento futuro (MURPHY, 1999). A maior diferença para com a análise fundamentalista é que esta busca prever a direção dos ativos através da análise de indicadores econômicos e de desempenho empresariais.

2.3.3 Impacto midiático no mercado

Os seres humanos possuem sentimentos que influenciam as decisões ao longo de sua vida, incluindo aquelas tomadas no âmbito profissional e financeiro. Como também possuidores de tais emoções, os investidores que atuam no mercado financeiro também se deixam influenciar pelo seu otimismo ou pessimismo pessoal, tomando decisões enviesadas por estes sentimentos (TVERSKY; KAHNEMAN, 1979).

Além disso, é de conhecimento científico, estudado no campo da psicologia do investidor, que o sentimento predominante no noticiário especializado em mercado financeiro afeta o desempenho das ações de maneira direta, com companhias de menor valor de mercado sendo as mais voláteis às notícias (NASEEM et al., 2021). Dessa forma, avaliar o sentimento das notícias veiculadas por portais especializados no mercado financeiro pode entregar uma previsão do comportamento dos índices acionários e suas volatilidades durante um certo tempo subsequente (KRÄUSSL; MIRGORODSKAYA, 2014).

Ademais, durante momentos de crise, caracterizados pela ampla divulgação de informações e notícias financeiras, as percepções dos investidores, sobretudo daqueles com menor patrimônio investido, tendem a mudar mais rapidamente que o normal, fazendo com que o volume e a recorrência de negociações no mercado financeiro aumentem (HOFFMANN; POST; PENNINGS, 2013). Apesar disto, a maioria dos investidores não param de investir durante grandes quedas da bolsa de valores, buscando com isso diminuir o risco e a volatilidade de suas carteiras, mas sim aproveitam momentos de baixa para comprar ativos a preços menores.

Atualmente, com o avanço da internet, é natural que haja um maior volume de informações disponíveis online, incluindo aquelas de portais, tanto amadores quanto profissionais, que discutem tópicos do mercado financeiro. Como já visto anteriormente, os portais especializados oferecem um panorama do sentimento prevalecente no mercado financeiro, podendo influenciar o processo decisório dos investidores. Quanto aos portais amadores, incluindo fóruns e *influencers* de finanças em redes sociais, sua influência sobre investidores iniciantes tende a provocar retornos ruins advindos de investimentos instigados por respostas sentimentais ao conteúdo online (WARKULAT; PELSTER, 2024).

No caso do Brasil, a maioria dos investidores pessoas físicas, ou seja, individuais, pode ser caracterizada pelo perfil de aplicação conservador, evitando investimentos em produtos que possam apresentar maior volatilidade, incluindo ações e índices acionários (PAIVA et al., 2020). Este perfil, derivado do histórico de ondas inflacionárias, crises e escândalos políticos e corporativos no país, além da falta de conhecimento em educação financeira, ajudam a explicar a baixa propensão dos investidores individuais nacionais ao risco percebido.

Por fim, o mercado financeiro no Brasil também é caracterizado pela compatibilidade com estudos do campo de finanças comportamentais, com o investidor brasileiro sendo suscetível a investir em ações com o desempenho recente alto, ignorando o natural retorno à média dos ativos negociados em bolsa (HALFELD; TORRES, 2001). Além disso, é dito que esta tendência de seguir o movimento padrão do mercado acaba sendo mais forte no mercado financeiro brasileiro do que em seu par americano. Analisando esta evidência, podemos supor que o investidor brasileiro é pelo menos igualmente passível, se não mais, de sofrer influência dos meios de comunicação e redes sociais em suas teses e decisões de investimento.

2.4 Trabalhos correlatos

Ao tratar sobre a correlação entre notícias e a performance de ações, Heston e Sinha (2016) encontraram que as notícias afetam o desempenho das empresas na bolsa de valores, com notícias positivas tendo um efeito menos duradouro que negativas. Para este trabalho, foi referenciado que o tipo textual, seu tratamento, e o horizonte de agregação de notícias afeta a capacidade de previsão dos retornos na bolsa de valores, com o uso de um modelo mais moderno melhorando a correlação, e a agregação de sentimentos a nível semanal criando uma previsão mais longínqua que o nível diário.

Outro ponto importante de comunicação de uma empresa de capital aberto são os relatórios financeiros trimestrais, com os autores Mian e Sankaraguruswamy (2012) investigando como esses informes podem influenciar a resposta do mercado. Utilizando da análise de sentimentos, os autores verificaram que o sentimento dominante no mercado possui grande influência em como este reage ao resultado da empresa, podendo causar um descolamento de curto prazo entre o valor intrínseco e o preço de mercado da empresa. Estes resultados corroboram a hipótese de que o

noticiário, influenciando o sentimento do mercado, pode influenciar a precificação de ações, de certa forma, desconexa ao *valuation* da empresa.

Utilizando modelos de *machine learning* para a análise de sentimentos, Khedr et al. (2017) atingiu uma alta acurácia na identificação de vieses positivos e negativos do noticiário. Foi concluído que a análise de sentimentos, aplicada em textos jornalísticos, pode ser utilizada para prever o comportamento de ações. Neste mesmo sentido, Tyas et al. (2023) encontrou que o modelo RoBERTa possui uma alta acurácia na identificação de sentimentos em notícias relacionadas ao mercado financeiro, sobressaindo outros modelos.

Ademais, Santos, Bianchi e Costa (2023) aplicaram uma derivação do modelo BERT adaptada para notícias financeiras em português, obtendo bons resultados em acurácia na identificação do sentimento dominante no mercado brasileiro e logo na economia como um todo. Apesar de não ter sido feito um estudo para alguma ação específica, o desenvolvimento de teses de investimento a partir dos dados de sentimento predominante no mercado atingiu resultados satisfatórios.

Por fim, Dahal et al. (2023), encontrou que o sentimento predominante nas mídias sociais exerce influência sobre os preços de ações negociadas em bolsa. Estando na mesma direção, o modelo desenvolvido por Ren, Liao e Gong (2020), se mostrou capaz de prover referências para o investidor no que tange a escolha da alocação de ativos, auxiliando na predição de tendências do mercado financeiro. Além disso, Raza et al. (2023), verificou que o sentimento da notícia e o seu cunho, ou categorização, podem exercer diferentes influências sobre determinados tipos de ações.

3. METODOLOGIA

A coleta de dados foi realizada a partir da utilização de ferramentas de *web-scraping*, com foco no *Selenium* para coleta automatizada de dados, e o uso do *Beautiful Soup* para leitura do HTML coletado. As dificuldades encontradas e soluções propostas foram descritas no tópico acerca do conjunto de dados, com este detalhando o processo de extração de dados em sua totalidade. Com a base de dados completa, foi realizada a análise dos sentimentos de cada fragmento textual fazendo uso das ferramentas BERT anteriormente descritas.

3.1 Bibliotecas e ferramentas utilizadas

Durante todo o trabalho foi utilizada a linguagem *python*, incluindo diversas bibliotecas e ferramentas inerentes à linguagem de programação. Assim, primeiramente, para a extração dos dados através do processo de *web scraping*, a biblioteca *Selenium* teve como função a navegação automatizada para a coleta dos dados na linguagem HTML de cada página online, a qual se deu através da ferramenta *webdriver* do navegador Edge da Microsoft.

Com os dados já coletados, a biblioteca *BeautifulSoup* foi utilizada para a leitura e extração dos textos necessários de dentro do HTML da página. Este processo, apesar de automatizado, teve que ser feito de forma individual entre cada página de notícias, visto que a estrutura de cada site variava e, logo, o modo de coleta e processamento de dados também.

Após a estruturação do conjunto de notícias, a biblioteca *transformers* foi utilizada para a aplicação do modelo de análise de sentimentos, neste caso, “lucas-leme/FinBERT-PT-BR”. Além disso, durante todo este processo a biblioteca *pandas* apresentou diversas funções ao permitir a estruturação dos dados e análises, com as bibliotecas *matplotlib* e *seaborn* sendo utilizadas para a plotagem gráfica.

Para a importação dos dados reais de performance das ações das cinco empresas analisadas, foi utilizada a biblioteca *yfinance* do provedor *Yahoo Finance*, que disponibiliza estes dados online de maneira gratuita. Além disso, as bibliotecas do python *matplotlib* e *seaborn*, juntamente com o Microsoft Power BI, foram utilizadas

para plotagens de resultados e avaliações do funcionamento do algoritmo, com a biblioteca *sklearn* sendo aplicada em alguns ajustes de base e cálculos. Para a realização de ajustes nas bases de dados e tratamento, as bibliotecas *regex*, *collections* e *unicodedata* foram empregadas.

Por fim, para a execução dos algoritmos aqui referidos foram utilizados os ambientes de programação *Jupyter Notebooks* e *Visual Studio Code*, estando eles instalados em uma máquina de chip Intel Core i7 que ofereceu capacidade para o processamento local das ferramentas.

3.2 Criação do Conjunto de Dados

O índice Ibovespa B3, como visto anteriormente, é composto por dezenas de empresas, muitas de menor porte, com a redação jornalística especializada não retratando todas elas de maneira frequentemente igual. Dessa forma, foram escolhidas as cinco empresas com maior participação no índice para se realizar a coleta das notícias e posterior análise.

As empresas escolhidas retratam os maiores setores presentes na bolsa de valores brasileira, havendo duas financeiras, e uma de cada um dos seguintes setores: utilidade pública, materiais básicos e petróleo. Conforme visto no referencial, estes quatro setores são os com maior relevância no índice brasileiro, englobando mais de 70% da participação no período analisado. A Tabela 1 dispõe as empresas escolhidas para a análise, assim como seus respectivos códigos de negociação no mercado brasileiro e participação na composição do índice no momento da análise.

Tabela 1 - Empresas escolhidas para a análise de notícias

Empresa	Código de Negociação	Participação
Vale S.A.	VALE3	10%
Petróleo Brasileiro S.A.	PETR3, PETR4	10%
Itaú Unibanco S.A.	ITUB4	8%
Banco Bradesco S.A.	BBDC3, BBDC4	5%
Centrais Elétricas Brasileiras S.A.	ELET3, ELET6	4%

Fonte: B3 (2025), adaptado pelo autor (2025)

Assim, foram escolhidos portais brasileiros de notícias do mercado financeiro baseados em alguns critérios estabelecidos pelo autor desta pesquisa. Em primeiro lugar, os portais deveriam ter publicações frequentes de textos jornalísticos próprios, com estes tendo foco exclusivo em acontecimentos do mercado financeiro. Ademais, os sites não deveriam apresentar restrições, como bloqueadores e testes de verificação de automações, que se impusessem como obstáculos à obtenção dos textos via *web-scraping*.

Por fim, através da biblioteca Selenium foram recolhidas informações de notícias dos meses de janeiro, fevereiro, março e abril do ano de 2025 acerca das empresas comentadas anteriormente, dos portais digitais Finance News, E-Investidor e Seu Dinheiro, os quais se encaixaram nas restrições combinadas anteriormente. Neste período, os retornos de cada ativo, assim como os retornos do índice Ibovespa e do dólar americano frente ao real brasileiro podem ser verificados na Tabela 2.

Tabela 2 – Retorno de cada ativo analisado, junto à ativos de comparação

Ativo	Jan/25	Fev/25	Mar/25	Abr/25
PETR4	+2,5%	-4,7%	+3,4%	-19,3%
VALE3	-0,1%	+1,8%	+2,8%	-6,8%
ITUB4	+10,6%	-5,5%	+8,2%	+13,3%
BBDC4	+6,1%	-7,0%	+12,7%	+8,4%
ELET3	+5,8%	+5,9%	+7,8%	+6,8%
Ibovespa	+5,0%	-2,6%	+6,1%	+3,7%
USD/BRL	-7,3%	-0,8%	-2,2%	-1,5%

Fonte: B3 (2025), adaptado pelo autor (2025)

Para garantir que o algoritmo apenas buscasse dados da empresa desejada, foi inserido no código um comando para filtrar cada portal de notícias pelo *ticker* da ação analisada, o qual, por padrão, os portais de notícias financeiras inserem na publicação para identificar à qual empresa ela está se referindo. Os dados extraídos foram compostos pelo título da notícia publicada, sua data de publicação, além do primeiro parágrafo do texto jornalístico, os quais, combinados, serviriam de base para a classificação do sentimento pelo modelo.

Assim, foi feita uma base de dados composta pelas 580 notícias que restaram após a aplicação dos filtros de data e de empresa, com a base de dados sendo importada na biblioteca *pandas* em python, a qual permite fácil aplicação dos

algoritmos de análise de sentimentos e armazenamento dos dados. Antes da aplicação do modelo de análise de sentimentos, foi feita uma limpeza da base de dados, excluindo eventuais registros repetidos e desconsiderando também publicações que trouxessem o conteúdo no formato de áudio ou vídeo, restando um total de 573 amostras.

Dentre as notícias, há casos de manchetes que não oferecem uma interpretação fácil do viés, havendo alguns retratos de acontecimentos pontuais inclusive de empresas além daquelas buscadas, o que, seguindo o esperado, deveria ter uma classificação neutra. Apesar disto, há vários casos de notícias sobre influenciadores estratégicos de cada empresa, com viés claramente positivo ou negativo, disponíveis para avaliação do algoritmo.

3.3 Sequência de Execução

Após a importação dos dados através do processo de web-scraping descrito no tópico anterior, a base de dados contendo o texto necessário para o processo de avaliação do sentimento foi armazenada em formato CSV. Cada amostra continha duas colunas de ligação com a informação de investimentos, sendo elas o *ticker* da empresa negociada e o nome do portal de notícias, uma coluna para inserção do sentimento na série temporal, representando a data em que a notícia foi veiculada, e por fim, a coluna de avaliação do sentimento.

Antes da aplicação do modelo de avaliação textual, foram executados alguns passos para garantir que a leitura do texto ocorresse da melhor forma, evitando que itens fora de contexto afetassem a interpretação do algoritmo. Assim, textos contendo *tickers* de empresas ou espaços duplos foram ajustados através da aplicação de uma função utilizando a biblioteca *regex*.

Para a realização da análise de sentimentos, o modelo “*lucas-leme/FinBERT-PT-BR*” foi importado através da biblioteca *transformers* proveniente da linguagem de programação *python*. Assim, este modelo avaliou cada um dos textos, acrescentando as colunas “sentimento” e “confiança” ao conjunto de dados previamente importado, sendo a primeira coluna a classificação resultante pelo modelo, que pode ser negativa, positiva ou neutra. A avaliação da quantidade de notícias inseridas em cada categoria por portal de notícias e por *ticker* de negociação em bolsa pode ser visualizada na seção de resultados.

Ademais, o *score* calculado pelo modelo, representado na coluna “confiança”, traz um número decimal que representa o nível de confiança do modelo em sua resposta, sendo o valor 0 representando a menor confiança e 1 a total confiança. Esta informação foi considerada útil para o trabalho devido ao fato de que notícias em que o modelo tem uma confiança maior devem conter um texto de maior cunho sentimental, e logo indicar uma maior presença daquele sentido de sentimento, devendo ganhar um peso maior na avaliação do que notícias de menor presença de sentimentos.

Em sequência, com a base de dados já contendo os sentimentos de cada amostra, foi feita a divisão entre os diferentes *tickers* e a transformação através do agrupamento por data como index, com as novas colunas trazendo o número de publicações e o percentual de notícias avaliadas como positivas, neutras ou negativas no período daquela amostra. A Tabela 3 abaixo retrata algumas linhas do *dataframe* transformado, possibilitando a visualização do percentual de sentimento do mercado para determinado dia e a força deste sentimento pelo número de amostras registrado.

Tabela 3 - Amostra do *dataframe* transformado para análise

Data	Número de amostras	% POSITIVE	% NEUTRAL	% NEGATIVE
06/01/2025	2	0,00	0,44	0,56
07/01/2025	2	0,64	0,00	0,36
08/01/2025	5	0,56	0,00	0,44

Fonte: autor (2025)

Para o cálculo dos percentuais retratados acima, foi utilizada a coluna de confiança do modelo explorada anteriormente, garantindo que o percentual de segurança do modelo em sua decisão fosse repassado para o restante da análise deste trabalho. Apesar do registro demonstrar o sentimento predominante no meio jornalístico para uma determinada ação em um dado dia, não era possível ainda verificar com clareza o efeito da junção do sentimento de um período de n dias anteriores em determinado dia.

Visando atingir esta visualização de maneira mais clara, foi criado o parâmetro de dias de sentimento, que traria para certa data a média dos últimos n dias dos sentimentos registrados, trazendo ainda a soma do total de número de notícias. Dessa

forma, foi possível repassar o efeito do sentimento das notícias jornalísticas dos dias anteriores para determinado período e avaliar o resultado desta mudança.

Após esta operação, foram importados os dados históricos das ações das cinco empresas analisadas através da biblioteca *yahoo finance*, sendo comparados os dados de fechamento de cada dia e a variação entre os dias de operação. Assim, da mesma forma que na base de sentimentos, foi feita a média móvel da performance da ação em x dias antes e depois de determinada data, com ambas sendo colocadas como colunas do *dataframe* e x sendo uma variável controlada. A Tabela 4 a seguir traz algumas amostras da base de dados final.

Tabela 4 - Parte do *dataframe* final com variações de ação

Data	Média Móvel Pré	Média Móvel Pós
23/01/2024	-0,71%	-0,20%
24/01/2024	-0,61%	-0,36%
25/01/2024	-0,68%	-0,17%

Fonte: autor (2025)

Em sequência, através do índice de datas em comum, as bases de dados de sentimentos e de ações foram mescladas em uma única base, com uma matriz dos coeficientes de correlação de pearson sendo gerada para averiguar a existência de alguma correlação em comum entre a média móvel de performance da ação x dias após a data analisada e o sentimento da ação n dias antes do período analisado. A Figura 2 demonstra a relação entre uma janela de sentimentos de três dias e uma janela de ações de cinco dias, mostrando o período final de correlação utilizado para a análise do algoritmo.

Figura 2 – Relação entre n sentimento e x ação

	n = 3	x = 5	final
1			
2			
3			
4			
5			
6			
7			
8			
9			
10			
11			
12			
13			
14			
15			
16			
17			
18			
19			
20			
21			
22			
23			
24			
25			
26			
27			
28			
29			
30			

Fonte: autor (2025)

Visando obter os melhores valores para os parâmetros variáveis x e n , foi executado um *loop* que trouxe para cada ação os coeficientes de correlação entre as colunas de cada base com ambas as variáveis abrangendo valores de 1 até 30, resultando em 900 valores de correlação para cada uma das cinco ações. A Tabela 5 a seguir traz algumas amostras do *dataframe* com os coeficientes de relação finais, mostrando as variações destes para cada combinação de x e n .

Tabela 5 - Parte do *dataframe* de correlação entre variáveis

Número de amostras	% POSITIVE	% NEUTRAL	% NEGATIVE	Variáveis		
Média Móvel Pós	Média Móvel Pós	Média Móvel Pós	Média Móvel Pós	n sentimento	x ações	Ticker
-0,02	0,23	-0,04	-0,19	1	1	vale3
0,11	0,20	0,08	-0,25	1	2	vale3
0,07	0,11	0,02	-0,11	1	3	vale3

Fonte: autor (2025)

Após a montagem desta tabela de dados, objetivando encontrar a escolha das variáveis n e x que entregasse o maior nível de correlação entre a performance das ações e as notícias, foi selecionado o n sentimento em que a média de correlação das três x ações de correlação mais forte fosse máximo. Com estes números, foi montada tanto uma análise para as correlações proporcionais como inversamente proporcionais. A Tabela 6 traz uma demonstração do resultado para a variável de número de amostras para a ação da empresa Vale, com os n sentimentos de maior força em ambos os sentidos e os pontos de x ações em que as três maiores forças foram observadas.

Tabela 6 - Amostra do *dataframe* com correlações mais fortes

Sentido	n sentimento	x ações: correlação
Positivo	21	{15: 0.5991, 16: 0.5932, 14: 0.5792}
Negativo	30	{30: -0.4498, 29: -0.4457, 28: -0.4281}

Fonte: autor (2025)

Assim, visando definir uma recomendação do algoritmo baseada no número mais forte, foi calculada a média entre os três x ações selecionadas, tanto positivos quanto negativos, com o maior valor sendo recomendado e a média classificada como a força final da recomendação. Este relatório foi feito para número de amostras, positivo, neutro e negativo, fazendo com que houvesse alguma recomendação para a ação se algum dos cenários acima apresentasse uma preponderância.

Com este procedimento, foi possível criar a recomendação de compra ou venda baseada no sentimento predominante e na quantidade de amostras dos últimos n dias com retorno esperado para os próximos x dias, como representado na Tabela 7 a seguir, que traz a recomendação para o número de amostras da empresa Vale. Para determinar se a recomendação de número de amostras era válida, os últimos n dias deveriam ter um volume de notícias acima da média.

Tabela 7 - Amostra do *dataframe* com correlações mais fortes

Parâmetro	Número de amostras
Sentido	Alta
n sentimento	21

Correlação	0,5905
x ação	15

Fonte: autor (2025)

Seguindo um exemplo parecido, o percentual de sentimento dos últimos n dias para uma ação deveria ser acima de meio para algum sentimento, positivo, neutro ou negativo, com a recomendação de sentimento sendo invalidada caso esse percentual mínimo não fosse atingido. Devido ao fato de que não seria possível mais de dois sentimentos registrarem um percentual maior de 50%, caso o percentual mínimo fosse atingido haveria apenas um único sentimento preponderante no mercado, com a recomendação relativa à este sentimento para aquela ação sendo buscada na base feita anteriormente.

Com as recomendações de cada uma das cinco empresas prontas, foi aplicada uma rodada de testes com os dados reais coletados após o dia 30 de abril, a qual foi a última data utilizada para geração das correlações. Nestes testes, foi avaliado após os x dias previstos pelo algoritmo o sentido da ação seguia a recomendação, com os resultados, separados entre recomendações por número de amostras e também por sentimentos, servindo para avaliar o sucesso da capacidade de previsão do algoritmo. Foi feita, por fim, uma simulação dos resultados, dividindo-os por amostras e sentimentos, simulando um aporte baseado no percentual de confiança e o retorno real de cada portfólio.

4. RESULTADOS E DISCUSSÃO


A partir da linha de trabalho escolhida, que incluiu a previsão de alta ou baixa para ações tanto a partir do sentimento predominante como também do número de amostras, os resultados se deram a partir da avaliação do percentual de acerto das recomendações e do retorno de uma carteira de investimentos simulada. Nesta seção, o foco foi o detalhamento dos resultados obtidos e suas implicações, revisitando os objetivos previamente definidos para este trabalho.

Além desta parte, foi feita primeiramente uma breve recapitulação do conjunto de dados de notícias, com a exploração dos dados por empresa e por portal jornalístico. Por fim, discutiu-se algumas das principais variações possíveis de serem executadas com essa mesma temática, demonstrando limitações deste trabalho, sugestões para trabalhos posteriores e análises semelhantes que podem ser realizadas a partir deste estudo.

4.1 Exploração de dados

Após a coleta de dados, retratada no tópico 3.1, a base de dados já continha as avaliações de sentimentos por portal de notícias e por empresa. Para retratar a dispersão de notícias por meios jornalísticos entre as empresas, o gráfico da Figura 3 traz os portais com mais notícias e o percentual que cada empresa representou nesse total.

Figura 3 - Contagem de amostras por portal de notícias por empresa




Fonte: autor (2025)

Ao verificar o gráfico da Figura 3, percebeu-se que as empresas com maior participação na bolsa de valores, sendo elas Petrobrás e Vale, apresentaram um número de notícias superior às demais, com o portal E-investidor também sendo preponderante. Apesar de aumentar o risco de enviesar a análise, este fato condiz com a disponibilidade de informações sobre as empresas, ainda possibilitando verificar se, a partir dos resultados, houve alguma influência negativa da escassez de reportagens.

Ademais, ao incluir a avaliação dos sentimentos na visualização por portal e por empresa, a Figura 4 abaixo ilustra a contagem de cada tipo de sentimento por cada portal. Analisando o gráfico, percebe-se que há uma boa distribuição entre os sentimentos por portal de notícias e por empresa, com todas as empresas possuindo notícias positivas, negativas e neutras disponíveis para análise. Este fato contribuiu para a eficácia da análise, demonstrando que apesar de empresas menos negociadas registrarem uma menor quantidade de informações, a distribuição de sentimentos entre estas amostras se manteve adequada.


Figura 4 - Contagem de sentimento por portal de notícias por empresa



Em sequência, a Figura 5 demonstra a distribuição do número de amostras ao longo do tempo por sentimento para o ativo PETR4, incluindo o gráfico com o desempenho da ação na bolsa de valores. Com este gráfico, foi possível validar que

não houve uma concentração de notícias em apenas um período, com todos os meses possuindo picos e vales em relação ao número de amostras.

Figura 5 – Sentimento de amostras e performance do ativo PETR4



Fonte: autor (2025)

Por fim, foi feita uma análise de frequência de palavras-chave por classificação de sentimento, sendo montada a Tabela 8, que trouxe as palavras mais frequentes encontradas exclusivamente nos textos dos conjuntos positivos e negativos. Para a criação desta tabela, foram desconsideradas palavras relacionadas às empresas ou de utilização exclusiva para manter a coesão gramatical.

Tabela 8 - Palavras-chave mais frequentes de cada classificação de sentimentos

Posição	Positivo	Negativo
1º	Transação	Recua
2º	Reservas	Caem
3º	Capacidade	Deslistagem

4º	Avança	Contra
5º	Ativo	Vendido
6º	Estendeu	Refinarias
7º	Concluída	Norte-americano
8º	Consumo	Importação
9º	Subiram	Tarifaço
10º	Classificação	Pressão

Fonte: autor (2025)

Analisando os dados contidos na Tabela 8, percebeu-se uma relação entre notícias classificadas como positivas e negociações empresariais como em “concluída” e “transação”. Houve ainda uma relação entre ativos empresariais, como “ativo” e “reservas”, com dados de mercado como “consumo” também influenciando positivamente o algoritmo.

Pelo lado das classificações negativas, palavras com tom fortemente desfavorável foram maioria dentre as dez palavras mais frequentes, sendo “recua”, “caem” e “pressão” exemplos. Houve ainda o registro das palavras “norte-americano”, “importação” e “tarifaço”, relacionadas às disputas comerciais entre Estados Unidos e outros países, as quais exerceram forte pressão negativa sobre as bolsas de valores, não sendo a brasileira uma exceção, durante o período da coleta dos dados jornalísticos.

Ademais, ainda na Tabela 8, é verificado que algumas palavras estão relacionadas a notícias que remetem a uma queda no preço das ações. Nestes casos, é provável que a relação de influência seja reversa, ou seja, o mercado influencie o sentimento do noticiário especializado.

Ao verificar que havia relação entre eventos reais e as principais palavras encontradas, o algoritmo de classificação de sentimentos foi considerado validado pelo autor deste trabalho. Dessa forma, o modelo “lucas-leme/FinBERT-PT-BR” desempenhou de forma satisfatória para a análise de notícias do mercado financeiro brasileiro e a classificação destas por sentimentos.

4.2 Análise da aplicação

Após a sequência de execução descrita na seção de metodologia, foram coletados os resultados de performance de recomendações, verificando a assertividade do algoritmo implementado. Dessa maneira, a Tabela 9 traz os dados de verificação, com as recomendações separadas pelo número de amostras e pelo sentimento de mercado, contendo ainda o sentido da sugestão, a força de correlação e o retorno do mercado passados os dias previstos pelo algoritmo.

Tabela 9 - Resultados da previsão do algoritmo de análise de notícias

Ticker	Gatilho	Previsão	<i>n</i> sentimento	x ação	Correlação	Retorno do mercado
vale3	Amostras	Alta	22	15	0,5905	4,90%
petr4	Amostras	Baixa	28	26	-0,6956	4,37%
itub4	Amostras	Sem tendência	-	-	-	-
elet3	Amostras	Baixa	28	23	-0,6193	-5,12%
bbdc4	Amostras	Sem tendência	-	-	-	-
vale3	Sentimento	Baixa	4	15	-0,5028	4,90%
petr4	Sentimento	Baixa	24	26	-0,6900	4,70%
itub4	Sentimento	Baixa	15	26	-0,7152	6,29%
elet3	Sentimento	Sem tendência	-	-	-	-
bbdc4	Sentimento	Baixa	4	23	-0,3452	14,07%

Fonte: autor (2025)

Analisando a Tabela 8, foi possível verificar que as recomendações levando em conta o sentimento de mercado se mostraram incorretas para todas as quatro previsões, com o mercado indo na direção oposta. Dentre estas previsões, houve casos de forças de correlação maiores e menores, mas todas com o mesmo resultado, indicando que o caminho adotado na construção do algoritmo não foi o ideal no quesito de previsibilidade de tendências de mercado com base em sentimentos de portais jornalísticos.

Verificando os dados para as sugestões referentes ao número de amostras, percebeu-se que das três sugestões disponíveis, duas acertaram a direção que o mercado seguiu no prazo estabelecido. Este resultado, mais positivo do que na categoria anterior, pode indicar que a quantidade de notícias é realmente um fator que

pode influenciar o preço dos ativos nos dias posteriores, entretanto a ação com a maior força de correlação ter sido a única com resultado aquém do esperado também pode indicar a falta de causalidade entre as variáveis, apontando apenas uma aleatoriedade no caso positiva para o escopo do trabalho.

Nestes resultados, não foi possível certificar que uma empresa entregou uma correlação mais precisa que outra, visto que os resultados de previsão consideraram apenas um único ponto temporal, somado ao fato de que não foram obtidos resultados que comprovassem a hipótese de correlação entre notícias e o desempenho das ações. Além disto, não foi possível distinguir o efeito que algum portal jornalístico específico exerceu sobre os resultados, visto que, visando aumentar a quantidade de amostras disponíveis, foram todas unidas em uma única base de dados.

Ademais, na Tabela 9 foi incluída uma simulação de carteira de investimentos considerando os gatilhos de número de amostras e de sentimentos. Para a avaliação dos retornos de cada sugestão, foi considerado o preço da ação nos períodos inicial e final, com indicativos de compra, ou alta, simulando a compra no período inicial e venda no final, e indicativos de venda, ou baixa, simulando exatamente o oposto. Os valores iniciais de ambas as carteiras de investimentos foram de uma quantidade y de reais, o qual foi dividido entre cada sugestão de acordo com a força do módulo da correlação.

Tabela 9 - Retornos simulados de carteiras de investimentos

Gatilho da carteira	Retorno total
Número de amostras	+1,59%
Sentimentos	-6,68%

Fonte: autor (2025)

Percebeu-se que a carteira simulando as sugestões baseadas no número de amostras representou um desempenho positivo, entretanto a mesma questão sobre a evidência de que esse desempenho indicou uma causalidade permaneceu. De modo contrário, verificou-se que o algoritmo não conseguiu prever satisfatoriamente o mercado com base na análise de sentimentos.

Apesar deste resultado contrário ao esperado, sobretudo para as recomendações envolvendo sentimentos, a anulação da hipótese de que o sentimento

dos registros jornalísticos pode atuar na previsão de preços de ativos negociados em bolsa não pôde ser confirmada. Isso se deu pelo fato de que o algoritmo implementado nesta pesquisa considerou apenas um caminho dentre os inúmeros meios possíveis de buscar correlações e construir sugestões de compra ou venda de ativos financeiros. Na próxima seção, que teve como foco explorar limitações deste estudo, foram discutidas algumas das decisões tomadas que conduziram este trabalho a esse rumo, assim como sugestões de variações que podem resultar em recomendações com maior acurácia.

4.3 Limitações e sugestões para futuros trabalhos

Após terem sido verificados os resultados, percebeu-se que o desempenho do algoritmo no que tange às recomendações de investimento ficou aquém do desejado, com a margem de acerto baixa. Dessa forma, esta seção trouxe as principais limitações identificadas neste estudo, buscando explicar o desempenho abaixo do esperado do algoritmo. Ao mesmo tempo, foram feitas sugestões para trabalhos futuros, indicando outros caminhos possíveis de serem seguidos e que podem gerar resultados mais promissores.

Dessa forma, tratando primeiramente dos dados brutos, a escolha dos portais de notícias por si só já pôde ser considerada uma limitação deste estudo. No quesito de informações financeiras online, as grandes empresas de mídia, como Valor e investing.com, concentram grande parte do tráfego virtual midiático no Brasil, ocasionando que o potencial de influência que eles possuem sobre o sentimento de mercado com uma notícia é muito maior que qualquer um dos portais escolhidos. Além disso, coletar dados destes grandes portais inclui maiores restrições, como barreiras digitais e legais fortemente estruturadas para coibir o uso desta informação.

Assim, devido a estas barreiras, o estudo não conseguiu capturar grande parte das notícias publicadas sobre o mercado na época, resultando em uma base com pouca frequência de notícias e que pode acabar não traduzindo o sentimento midiático sobre uma determinada empresa. Apesar da influência negativa na possibilidade de descoberta de uma eventual correlação entre as notícias e o desempenho dos ativos, a não utilização dos grandes portais jornalísticos não foi considerada um impeditivo para a realização do estudo. Isto se deu visto que os portais escolhidos, sendo estes de menor porte, também publicam registros dos acontecimentos relevantes

relacionados às empresas analisadas, trazendo ao menos parte do sentimento predominante e do número de amostras por data dos grandes portais jornalísticos.

Em sequência, ainda tratando da base de dados, outra limitação do estudo foi a abrangência temporal, que incluiu um período relativamente curto para a identificação de um padrão forte de correlação. Como visto anteriormente, o mercado de valores brasileiro possui uma volatilidade alta, com um período de quatro meses podendo ser altamente influenciado por algum movimento forte de algum ativo. Além disso, a alta capacidade de precificação de notícias pelo mercado financeiro, com o reflexo de novas informações ocorrendo de maneira imediata nos preços dos ativos também podendo impactar o sucesso desta pesquisa.

Apesar de a escolha de cinco ativos diferentes auxiliar na mitigação deste problema, o uso de um período de dados maior talvez contribuisse para uma melhora nos resultados previstos pelo algoritmo. Ainda neste quesito, o aumento da base de ativos para além de cinco, apesar de, à primeira vista, parecer contribuir com o resultado, pode não ser uma boa escolha, visto que o volume de notícias no Brasil para empresas que não estejam entre as maiores começa a ficar escasso, podendo enviesar a análise e piorar os indicadores de correlação. Neste caso, a avaliação de ativos populares, incluindo o próprio índice Ibovespa B3 como um todo, ou até mesmo a relação entre dólar e real, são outras possibilidades válidas, assim como o uso de notícias de fatores macroeconômicos e a verificação da influência destes nas ações de empresas.

Tratando agora do modelo utilizado para a avaliação de sentimentos, seus resultados foram considerados satisfatórios, sobretudo ao observar a lista de palavras mais comuns exclusivas dos conjuntos de dados positivo e negativo. A listagem destas palavras também pode ser utilizada de forma mais profunda para o aprimoramento da comunicação empresarial, evitando que falhas de comunicação ocasionem perdas no mercado. A utilização do primeiro parágrafo de cada notícia também se mostrou acertada, visto que a partir deste texto o algoritmo foi capaz de identificar o sentimento de maneira adequada. Ainda assim, a sugestão de testar outros modelos de análise de sentimentos é válida, sobretudo em casos de fontes de dados diferentes das utilizadas neste estudo.

Ademais, a sequência de passos que resumem o algoritmo que buscou correlações entre as notícias já classificadas e a performance real das ações oferece uma vasta gama para aprimoramentos e alterações. Primeiramente, o não uso de

informações como portal jornalístico e tendência de mercado antes do período de avaliação restringiram o total de dados disponíveis para a busca de correlações. Para a utilização total dessa capacidade que a base de notícias e de ações ofereciam, seria recomendado o aumento da amostragem, permitindo uma maior granularidade sem arriscar a redução da amostragem por grupo de dados.

Além desta possível mudança, a adoção de uma abordagem diferente da utilizada para correlacionar a base de notícias com a de ações poderia ser uma alternativa para encontrar previsões melhores. Uma nova abordagem poderia variar desde com o uso de um n ou x diferentes para a média de sentimentos e de desempenho futuro, ou a alteração de algum dos cálculos de medidas, condizendo com um potencial período maior, ou até mesmo a criação de um algoritmo totalmente novo.

Por fim, uma outra possível fonte de diferenciação está na parte de geração de recomendações, que neste trabalho analisou quais seriam os parâmetros que provocaram o maior nível de correlação, aplicando-os caso as condições mínimas de quantidade de amostras e sentimento preponderante fossem atingidas. Algumas alterações possíveis incluem a mudança de condições mínimas, o uso de número de amostras abaixo da média além da acima da média usada, a avaliação da performance prévia pela média móvel dos retornos anteriores, e o teste com mais períodos além do último disponível. Assim, para a realização destas alterações, o algoritmo deveria passar por uma profunda mudança, entretanto os pressupostos e cálculos aqui descritos poderiam ser mantidos.

5. CONCLUSÃO

Em suma, o seguinte trabalho teve como objetivo central a construção de um algoritmo que buscasse uma relação de influência entre o sentimento dos portais de notícias e o retorno das ações no mercado financeiro. Juntamente à isto, foram objetivos deste estudo explorar a capacidade de classificação de sentimentos de um modelo baseado em BERT, verificar as possibilidades de comunicação empresarial para evitar atritos desnecessários entre corporações e o mercado financeiro, além de prover o meio acadêmico de maiores orientações para trabalhos futuros com esta mesma temática.

Os resultados obtidos não demonstraram a existência de uma relação de causalidade entre o sentimento passado de portais de notícias e o desempenho futuro do mercado financeiro. Apesar disto os resultados abriram caminho para inúmeras análises com variações da metodologia utilizada neste trabalho, incluindo até mesmo a busca por uma relação inversa à estudada. O desempenho ruim das previsões de mercado feitas pelo algoritmo seguiu a tendência de que, devido às diversas variáveis que influenciam o desempenho das ações, a criação de um algoritmo que realizasse previsões assertivas seria de grande impraticabilidade real.

Ademais, a pesquisa obteve sucesso em demonstrar a aplicabilidade do modelo FinBERT na associação de sentimentos à textos jornalísticos do mercado financeiro, auxiliando na melhora da comunicação empresarial no processo. O uso da coleta de dados através do *web-scraping* também se mostrou válido para este trabalho. Os testes de outras possibilidades de associações a partir dos resultados desta pesquisa também são válidos, contribuindo para o desenvolvimento científico na área.

BIBLIOGRAFIA

ADOMA, Acheampong Francisca; HENRY, Nunoo-Mensah; CHEN, Wenyu. Comparative analyses of bert, roberta, distilbert, and xlnet for text-based emotion recognition. In: **2020 17th international computer conference on wavelet active media technology and information processing (ICCWAMTIP)**. IEEE, 2020. p. 117-121.

AFTAN, Sulaiman; SHAH, Habib. A survey on bert and its applications. In: **2023 20th Learning and Technology Conference (L&T)**. IEEE, 2023. p. 161-166.

ARAÚJO, Matheus et al. Métodos para análise de sentimentos no twitter. In: **Proceedings of the 19th Brazilian symposium on Multimedia and the Web (WebMedia'13)**. sn, 2013. p. 19.

B3 – BRASIL, BOLSA, BALCÃO. Índice Ibovespa – Composição da carteira. B3, 2025. Disponível em: <http://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/indice-ibovespa-ibovespa-composicao-da-carteira.htm>. Acesso em: 01 jun. 2025

BENEVENUTO, Fabrício; RIBEIRO, Filipe; ARAÚJO, Matheus. Métodos para análise de sentimentos em mídias sociais. In: **Short course in the Brazilian Symposium on Multimedia and the Web (Webmedia)**. 2015. p. 1-30.

BEYSOLOW, Taweh. Applied natural language processing with python. 2018.

CHOWDHARY, K. R. Natural language processing. **Fundamentals of artificial intelligence**, p. 603-649, 2020.

COIMBRA, Mariana Victória Souza et al. Análise de sentimentos e emoções de tweets sobre a guerra da Ucrânia. 2023.

DAHAL, Keshab Raj et al. **A comparative study on effect of news sentiment on stock price prediction with deep learning architecture**. Plos one, v. 18, n. 4, p. e0284695, 2023.

DRUS, Zulfadzli; KHALID, Haliyana. Sentiment analysis in social media and its application: Systematic literature review. *Procedia Computer Science*, v. 161, p. 707-714, 2019.

DUPONT, Yoann et al. Structured named entity recognition by cascading CRFs. In: **Computational Linguistics and Intelligent Text Processing: 18th International Conference, CICLing 2017, Budapest, Hungary, April 17–23, 2017, Revised Selected Papers, Part I 18**. Springer International Publishing, 2018. p. 249-263.

FRANCO, Gustavo HB. A inserção externa e o desenvolvimento. **Brazilian Journal of Political Economy**, v. 18, n. 3, p. 121-147, 1998.

GOMES, Helder Joaquim Carvalheira. **Text Mining: análise de sentimentos na classificação de notícias**. 2013. Dissertação de Mestrado. Universidade NOVA de Lisboa (Portugal).

GRÔPPO, Gustavo de Souza. Relação dinâmica entre Ibovespa e variáveis de política monetária. **Revista de Administração de Empresas**, v. 46, p. 72-85, 2006.

HALFELD, Mauro; TORRES, Fábio de Freitas Leitão. Finanças comportamentais: aplicações no contexto brasileiro. **Revista de administração de empresas**, v. 41, p. 64-71, 2001.

HE, Ying; KAYAALP, Mehmet. A Comparison of 13 Tokenizers on MEDLINE. Bethesda, MD: **The Lister Hill National Center for Biomedical Communications**, v. 48, 2006.

HESTON, Steven L.; SINHA, Nitish Ranjan. News versus sentiment: Predicting stock returns from news stories. 2016.

HOFFMANN, Arvid OI; POST, Thomas; PENNING, Joost ME. Individual investor perceptions and behavior during the financial crisis. **Journal of Banking & Finance**, v. 37, n. 1, p. 60-74, 2013.

HUTCHINS, John. Machine translation: A concise history. **Computer aided translation: Theory and practice**, v. 13, n. 29-70, p. 11, 2007.

HUTCHINS, W. John. Machine translation: A brief history. In: **Concise history of the language sciences**. Pergamon, 1995. p. 431-445.

IGARASHI, Wagner; VALDEVIESO, Guilherme Soares; IGARASHI, Deisy Cristina Corrêa. Análise de sentimentos e indicadores técnicos: Uma análise da correlação dos preços de ativos com a polaridade de notícias do mercado de ações. **Brazilian Journal of Business**, v. 3, n. 1, p. 470-486, 2021.

JALE, Jader S. et al. Information flow between Ibovespa and constituent companies. **Physica A: Statistical Mechanics and its Applications**, v. 516, p. 233-239, 2019.

JUNIOR, Marcos Yuri Rosa. **Comparando BERT, RoBERTa e DistilBERT para análise de sentimentos em texto**. 2021. Trabalho de Conclusão de Curso. Universidade Tecnológica Federal do Paraná.

KHEDR, Ayman E. et al. Predicting stock market behavior using data mining technique and news sentiment analysis. **International Journal of Intelligent Systems and Applications**, v. 9, n. 7, p. 22, 2017.

KRÄUSSL, Roman; MIRGORODSKAYA, Elizaveta. News media sentiment and investor behavior. CFS Working Paper Series, 2014.

KUMAR, Rajesh. **Strategies of banks and other financial institutions: Theories and cases**. Elsevier, 2014. p. 95.

LEESON, William et al. Natural language processing (NLP) in qualitative public health research: a proof of concept study. **International Journal of Qualitative Methods**, v. 18, p. 1609406919887021, 2019.

LI, Xiaodong et al. Enhancing quantitative intra-day stock return prediction by integrating both market news and stock prices information. **Neurocomputing**, v. 142, p. 228-238, 2014.

LIU, Shanshan et al. Neural machine reading comprehension: Methods and trends. **Applied Sciences**, v. 9, n. 18, p. 3698, 2019.

MCINDOE, James. Power of the News: Tactical Asset Allocation Strategies Derived Using Sentiment Analysis. **Mathematics and Finance, Imperial College London**, 2018.

MIAN, G. Mujtaba; SANKARAGURUSWAMY, Srinivasan. Investor sentiment and stock market response to earnings news. **The Accounting Review**, v. 87, n. 4, p. 1357-1384, 2012.

MICHIE, Ranald. The London stock exchange: A history. **OUP Oxford**, 2001. p. 15-16.

MURPHY, John J. **Technical analysis of the financial markets: A comprehensive guide to trading methods and applications**. Penguin, 1999.

NASCIMENTO, Paula; OSIEK, Bruno; XEXÉO, Geraldo. Análise de sentimento de tweets com foco em notícias. **Revista Eletrônica de Sistemas de Informação**, v. 14, n. 2, 2015.

NASEEM, Sobia et al. The investor psychology and stock market behavior during the initial era of COVID-19: a study of China, Japan, and the United States. **Frontiers in psychology**, v. 12, p. 626934, 2021.

NEVIN, John A. Quantitative analysis. **Journal of the Experimental Analysis of Behavior**, v. 42, n. 3, p. 421-434, 1984.

OJEDA, Daniel Zonta; ZALEWSKI, Willian; MALETZKE, André Gustavo. Utilizando a quantificação na análise de sentimentos em reviews de produtos. In: **Escola Regional de Banco de Dados (ERBD)**. SBC, 2024. p. 71-80.

ORPHANOS, Giorgos et al. Decision trees and NLP: A case study in POS tagging. In: **Proceedings of annual conference on artificial intelligence (ACAI)**. 1999.

PAIVA, Raiane Thainá et al. O perfil do investidor individual no mercado financeiro. **Revista Vianna Sapiens**, v. 11, n. 2, p. 30-30, 2020.

PINTO, Alexandre; OLIVEIRA, Hugo Gonçalo; ALVES, Ana Oliveira. Comparing the performance of different NLP toolkits in formal and social media text. In: **5th Symposium on Languages, Applications and Technologies (SLATE'16)(2016)**. Schloss Dagstuhl–Leibniz-Zentrum fuer Informatik, 2016.

RAY, Partha Pratim. ChatGPT: A comprehensive review on background, applications, key challenges, bias, ethics, limitations and future scope. **Internet of Things and Cyber-Physical Systems**, v. 3, p. 121-154, 2023.

RAZA, Shahid et al. Uncovering the effect of news signals on daily stock market performance: An econometric analysis. **International Journal of Financial Studies**, v. 11, n. 3, p. 99, 2023.

REN, Yinghao; LIAO, Fangqing; GONG, Yongjing. Impact of news on the trend of stock price change: An analysis based on the deep bidirectiona LSTM model. **Procedia Computer Science**, v. 174, p. 128-140, 2020.

RIOS, Eyder et al. Exploração Eficiente de Estruturas de Vizinhaça em Ambientes Híbridos CPU/GPU. **Simpósio Brasileiro de Pesquisa Operacional**, p. 4128-4139, 2016.

ROTHMAN, Denis. **Transformers for Natural Language Processing: Build innovative deep neural network architectures for NLP with Python, PyTorch, TensorFlow, BERT, RoBERTa, and more**. Packt Publishing Ltd, 2021. p. 26-27.

ROTHMAN, Denis. **Transformers for Natural Language Processing: Build, train, and fine-tune deep neural network architectures for NLP with Python, Hugging Face, and OpenAI's GPT-3, ChatGPT, and GPT-4**. Packt Publishing Ltd, 2022. p. 57-58.

SALUSTIANO, Skrol. Análise de sentimento. **Monitoramento e pesquisa em mídias sociais: metodologias, aplicações e inovações**, 2016.

SANTOS, Lucas L.; BIANCHI, Reinaldo AC; COSTA, Anna HR. Finbert-pt-br: Análise de sentimentos de textos em português do mercado financeiro. In: **Brazilian Workshop on Artificial Intelligence in Finance (BWAIF)**. SBC, 2023. p. 144-155.

SCHUMAKER, Robert P.; CHEN, Hsinchun. A quantitative stock prediction system based on financial news. **Information Processing & Management**, v. 45, n. 5, p. 571-583, 2009.

SELAN, Beatriz. **Mercado financeiro**. UniSEB-Centro Universitário. Editora Universidade Estácio de Sá, v. 13, 2015. p. 108-110.

SHARMA, Surbhi; KAUSHIK, Baijnath. Quantitative analysis of stock market prediction for accurate investment decisions in future. **Journal of Artificial Intelligence**, v. 11, n. 1, p. 48-54, 2018.

SOARES, Luan Wallacy Vieira; FIRME, Vinícius de Azevedo Couto; JÚNIOR, Luiz Antônio de Lima. O impacto da política monetária no mercado de ações brasileiro. **Brazilian Review of Finance**, v. 19, n. 1, p. 70-96, 2021.

TEWELES, Richard J.; BRADLEY, Edward S. **The stock market**. John Wiley & Sons, 1998. p. 3.

TVERSKY, Amos; KAHNEMAN, Daniel. **Prospect theory: An analysis of decision under risk**. David K. Levine, 1979.

TYAS, Salsabila Mazya Permataning et al. A robustly optimized BERT using random oversampling for analyzing imbalanced stock news sentiment data. In: **2023 International Conference on Computer Science, Information Technology and Engineering (ICCoSITE)**. IEEE, 2023. p. 897-902.

VASWANI, Ashish et al. Attention is all you need. *Advances in neural information processing systems*, v. 30, 2017.

WANG, Ruizhe et al. Is greater connectivity of financial and non-financial information in annual reports valued by market participants?. **The British Accounting Review**, v. 56, n. 6, p. 101407, 2024.

WARKULAT, Sonja; PELSTER, Matthias. Social media attention and retail investor behavior: Evidence from r/wallstreetbets. **International Review of Financial Analysis**, v. 96, p. 103721, 2024.

YU, Yang; DUAN, Wenjing; CAO, Qing. The impact of social and conventional media on firm equity value: A sentiment analysis approach. **Decision support systems**, v. 55, n. 4, p. 919-926, 2013.

ZHU, Chenguang. **Machine reading comprehension: algorithms and practice**. Elsevier, 2021. p. 3.